

## Residual-эмбединги поверх готового риск-скора

Один принцип для отрасли и для региона: не пересчитываем дефолт, а учим поправку к frozen boost score. Сначала ОКВЭД, затем региональная модель, в конце — почему более ранние постановки не дали прироста.

### 🕒 Главный тезис

И ОКВЭД, и регион объясняют только остаток после индивидуального сора:  $\text{logit}(p_{\text{final}}) = \text{logit}(p_{\text{boost}}) + \alpha \cdot \Delta$ .

**+1.2 п.п.**

ПК OOT, ОКВЭД flat residual NN

**+0.7 п.п.**

ПК OOT, региональная модель

**0**

ПК OOT, ОКВЭД hierarchical

## 1. ОКВЭД

Учим отраслевую поправку к готовому boost score. Две архитектуры: flat по полному коду и hierarchical по уровням кода.

### Постановка

$$\text{logit}(p_{\text{final}}) = \text{logit}(p_{\text{boost}}) + \alpha \cdot \Delta_{\text{OKVED}}$$

Здесь  $\text{logit}(p) = \ln(p / (1 - p))$ . Это перевод вероятности в шкалу логарифма шансов (log-odds), где добавки интерпретируются естественно.

$$p_{\text{final}} = \text{sigmoid}(\text{logit}(p_{\text{boost}}) + \alpha \cdot \Delta_{\text{OKVED}})$$

$p_{\text{boost}}$  — готовая вероятность существующего бустинга.

$\Delta_{\text{OKVED}}$  — поправка, которую нейросеть вычисляет только из ОКВЭД.


$\alpha$  — обучаемая сила поправки: если отраслевой сигнал слаб, модель может уменьшить его влияние.

### 🕒 Безопасный старт

Последний слой инициализирован нулями. До обучения  $\Delta_{\text{OKVED}} = 0$ , то есть  $p_{\text{final}}$  в точности совпадает с  $p_{\text{boost}}$ .

### Структура модели

На входе всегда один готовый score и один основной ОКВЭД. Меняется только способ получить отраслевое представление.



B — размер batch. Бустинг не входит в нейросеть и не обновляется при ее обучении.


## Два варианта encoder

Flat: полный код

Hierarchical: уровни кода

### Hierarchical architecture


Разделяет представление ОКВЭД по уровням. Даже если полный код новый, сеть может использовать уже изученные родительские уровни.




### Пример переноса сигнала

Для нового кода 46.74.9 leaf-уровень — UNK, но уровни 46 и 46.74 остаются известными и участвуют в расчете.

## Граф нейронной сети по слоям





## Обучение и контроль утечки

### Временной split

Train — прошлый период; validation — следующий; test — самый свежий период. Так проверяем устойчивость во времени.

### OOF / frozen score

На train используем OOF boost score. На validation/test — скор модели, не обучавшейся на соответствующих таргетах.

### Vocabulary только train

Словари ОКВЭД строятся только по train: PAD для отсутствующего уровня, RARE для редкого и UNK для нового кода.

$$\text{Loss} = -\text{mean}(y \cdot \ln(p_{\text{final}}) + (1-y) \cdot \ln(1-p_{\text{final}}))$$

Минимизируем бинарную cross-entropy (BCE), early stopping выбирает эпоху по validation loss.

### Результаты: прирост Gini к boost score

Gini = 2 · ROC AUC − 1. Ниже — только ОКВЭД-ветки, без региональной модели. Hierarchical на ПК OOT = 0.

$$\text{Gini} = 2 \cdot \text{ROC AUC} - 1$$

## ПК

■ Train, н.н. Gini


■ OOT, н.н. Gini

## КК

■ Train, н.н. Gini

■ OOT, н.н. Gini

+3.1



Прирост Gini к boost score, п.п. Hierarchical OOT: 0.

Та же шкала. OOT слабее: выборка КК меньше.

| Продукт | Сплит | Flat residual NN | Hierarchical residual NN |
|---------|-------|------------------|--------------------------|
| • ПК    | Train | +2.0 п.п.        | +2.0 п.п.                |
| • ПК    | OOT   | +1.2 п.п.        | +0.0 п.п.                |
| • КК    | Train | +1.7 п.п.        | +3.1 п.п.                |
| • КК    | OOT   | +0.7 п.п.        | +0.3 п.п.                |

#### 🔗 Вывод по ПК

На OOT работает flat residual NN: +1.2 п.п. Gini. Hierarchical на train +2.0 п.п., на OOT прирост = 0 — иерархия не переносится.

#### ⚠ Вывод по КК

На OOT flat +0.7 п.п., hierarchical +0.3. На train hierarchical +3.1 п.п. — сильное переобучение. Оценки менее стабильны: меньше данных, чем у ПК.

#### ❌ ПК и КК нельзя учить совместно

Слишком большая разница в масштабе loss. Совместное обучение математически нетривиально и в текущем пайплайне не делается.

## 2. Региональная модель

Тот же residual-принцип, но вход — два адресных региона: регистрации и фактический. Сеть учит взаимодействие пары, а не один код.

### Постановка

$$\text{logit}(p_{\text{final}}) = \text{logit}(p_{\text{boost}}) + \alpha \cdot \Delta_{\text{region}}$$

Формула совпадает с ОКВЭД. Меняется только источник  $\Delta$ : здесь это пара регионов, а

$p_{\text{boost}}$  — тот же frozen / OOF-скор бустинга.

$\Delta_{\text{region}}$  — поправка из регистрации, фактического региона и флага их равенства.

...она зависит. Последний свой тоже индексирует по комбинации p\_final

Формула совпадает с ОКВЭД. Меняется только источник  $\Delta$ : здесь это пара регионов, а не отрасль.

$\alpha$  — сила поправки. Последний слой тоже нулевой: до обучения  $p_{\text{final}} = p_{\text{boost}}$ .

$$p_{\text{final}} = \text{sigmoid}(\text{logit}(p_{\text{boost}}) + \alpha \cdot \Delta_{\text{region}})$$

#### Безопасный старт


Residual head инициализирован нулями. Региональная ветка не может сдвинуть скор, пока не найдет устойчивый остаточный сигнал.

#### Структура модели

Общая таблица эмбедингов на 70 регионов. Признаки — не только два вектора, но и [разность], поэлементное произведение и equal\_flag.



#### Граф нейронной сети по слоям



Boost score не идет в encoder. Размерность взаимодействий:  $4 \cdot 4 + 1 = 17$ .

## Обучение и контроль утечки

### Временной split

Тот же протокол, что у ОКВЭД: train / validation / OOT-test по времени.

### OOF / frozen score

На train — OOF boost score. На validation и test — скор модели, не видевшей эти таргеты.

### Общий словарь регионов

Одна таблица  $70 \times 4$  на регистрацию и факт. Регион не кодируется отдельно «как категория бустинга».

$$\text{Loss} = -\text{mean}(y \cdot \ln(p_{\text{final}}) + (1-y) \cdot \ln(1-p_{\text{final}}))$$


Та же BCE, что у ОКВЭД. Early stopping по validation loss.

## Результаты: прирост Gini к boost score

Та же метрика: прирост Gini в п.п. к frozen boost score.  $\text{Gini} = 2 \cdot \text{ROC AUC} - 1$ .

■ Train, п.п. Gini

■ OOT, п.п. Gini



Прирост Gini региональной модели к boost score, п.п.

| Продукт | Train     | OOT       |
|---------|-----------|-----------|
| • ПК    | +1.2 п.п. | +0.7 п.п. |
| • КК    | +2.0 п.п. | +0.3 п.п. |

#### ⚙ Вывод по ПК

Региональная модель дает +0.7 п.п. Gini на OOT и +1.2 на train. Сигнал переносится во времени, слабее ОКВЭД-flat (+1.2 OOT), но устойчивее hierarchical (0 на OOT).

#### ⚙ ПК и КК нельзя учить совместно

Та же причина, что у ОКВЭД: слишком большая разница в масштабе loss. Совместное обучение математически нетривиально и не делается.

### 3. Почему не сработали более ранние эксперименты

До residual-постановки проверяли четыре подхода «в лоб». Ни один не дал устойчивого прироста к готовому boost score — ни для ОКВЭД, ни как замена региональной ветке.

#### Категория прямо в CatBoost

Полные коды и регионы высококардинальны и неравномерны. Для редкого значения наблюдений недостаточно, чтобы надежно оценить отдельный эффект.

#### FMM — смесь распределений

Ищет скрытые группы с разным средним риском:  $P(y) = \sum_k p_k \cdot P(y | \text{группа } k)$ .

Это безусловный PD группы. Большая часть такого сигнала уже сидит в boost score; редкие коды нестабильно относятся к компонентам. Прироста не было.

#### ⚠ Вывод по КК

На OOT +0.3 п.п., на train +2.0. Эффект меньше и менее стабилен: выборка КК меньше. Как и для ОКВЭД, train-прирост сам по себе не аргумент.

#### Нейросеть без boost score

Сеть видит только отрасль или регион и не видит персональный риск, который бустинг уже извлек из дохода, платежной дисциплины и других факторов.

#### Factorization machines

Учит взаимодействия через скрытые векторы:  $\hat{y} = w_0 + \sum_i w_i x_i + \sum_{i,j} \langle v_i, v_j \rangle x_i x_j$ .

Для редкого кода вектор  $v$  почти не оценивается. FM ловит парные пересечения, а не иерархию отрасли, не пару регионов и не остаток после индивидуального сора. Прироста тоже не было.

#### ⚠ Все четыре подхода конкурируют с бустингом

FMM отвечает: «насколько группа в среднем плохая». FM отвечает: «с какими признаками код пересекается». Residual-сеть отвечает иначе: «насколько этот ОКВЭД или эта пара регионов меняет шансы сверх уже учтенного сора».

#### ⚙ Поэтому остались две residual-ветки

ОКВЭД и регион объясняют только  $\Delta$  к log-odds готовой модели. Без этой постановки ранние эксперименты забирали сигнал, который бустинг уже умеет.