

dual-эмбединги поверх готового риск-скора

инцип для отрасли и для региона: не пересчитываем дефолт, а учим поправку к ost score. Сначала ОКВЭД, затем региональная модель, в конце — почему более остановки не дали прироста.

й тезис

Д, и регион объясняют только остаток после индивидуального сора: $\text{logit}(p_{\text{final}}) = \text{logit}(p_{\text{boost}}) + \alpha \cdot \Delta$.

! п.п.

ОКВЭД flat residual NN

+0.7 п.п.

ПК OOT, региональная модель

0

ПК OOT, ОКВЭД hierarchical

ВЭД — постановка

ислеваю поправку к готовому boost score. Две архитектуры: flat по полному коду и hierarchical по уровням кода.

$$p_{\text{final}} = \text{logit}(p_{\text{boost}}) + \alpha \cdot \Delta_{\text{OKVED}}$$

$\text{log}(p / (1 - p))$. Добавки живут в шкале log-odds.

$$l = \text{sigmoid}(\text{logit}(p_{\text{boost}}) + \alpha \cdot \Delta_{\text{OKVED}})$$

p_{boost} — готовая вероятность существующего б

Δ_{OKVED} — поправка только из ОКВЭД.

α — сила поправки: если сигнал слаб, модель умень

влияние.

Безопасный старт

Последний слой инициализирован нулями. До обу

$\Delta_{\text{OKVED}} = 0$, то есть p_{final} совпадает с p_{boost} .

Д — структура модели

один готовый score и один основной ОКВЭД. Меняется только способ получить отраслевое представление.




batch. Бустинг не входит в нейросеть и не обновляется при ее обучении.

Д — два encoder

Листовой код

Вектор на leaf-код. Лучше, когда наблюдений достаточно.



Листа

Лист или новый leaf получает общий RARE/UNK embedding.

Hierarchical: уровни кода

Даже новый полный код может опереться на известных родителей.



Перенос

Для 46.74.9 leaf = UNK, но 46 и 46.74 остаются в расчете.

Д — обучение

ной split

рошлый период; validation —
ций; test — самый свежий. Проверяем
зость во времени.

OOF / frozen score

На train — OOF boost score. На validation/test —
скор модели, не обучавшейся на этих
таргетах.

Vocabulary только train

PAD для отсутствующего уровня, RARE
редкого, UNK для нового кода.

$$-\text{mean}(y \cdot \ln(p_{\text{final}}) + (1-y) \cdot \ln(1-p_{\text{final}}))$$


уруем BCE. Early stopping выбирает эпоху по validation loss.

$$2 \cdot \text{ROC AUC} - 1$$

ьше — прирост Gini в п.п. к frozen boost score. +1 п.п. Gini = +0.5 п.п. AUC.

Д — результаты Gini

ВЭД-ветки. Hierarchical на ПК OOT = 0.



Д — вывод

Сплит	Flat residual NN	Hierarchical residual NN
Train		+2.0 п.п.
OOT		+1.2 п.п.
Train		+1.7 п.п.
OOT		+0.7 п.п.

по ПК
работает flat residual NN: +1.2 п.п. Gini. Hierarchical на train +2.0, на OOT
Г = 0 — иерархия не переносится.

Вывод по КК
На OOT flat +0.7, hierarchical +0.3. На train hierarchic
— сильное переобучение. Меньше данных, чем у Г

нельзя учить совместно
м большая разница в масштабе loss. Совместное обучение математически нетривиально и не делается.

Региональная модель — постановка

Residual-принцип, но вход — два адресных региона: регистрации и фактический. Сеть учит взаимодействие пары, а не один код

$$p_{\text{final}} = \text{logit}(p_{\text{boost}}) + \alpha \cdot \Delta_{\text{region}}$$

совпадает с ОКВЭД. Меняется только источник Δ .

$$l = \text{sigmoid}(\text{logit}(p_{\text{boost}}) + \alpha \cdot \Delta_{\text{region}})$$

p_boost — тот же frozen / OOF-скор бустинга.

Δ_{region} — поправка из регистрации, фактического региона и флага равенства.


α — сила поправки. Последний слой нулевой: до о $p_{\text{final}} = p_{\text{boost}}$.

Безопасный старт

Региональная ветка не сдвигает скор, пока не найден устойчивый остаточный сигнал.

Базовая модель — структура

Матрица эмбедингов на 70 регионов. Признаки — два вектора, |разность|, произведение и equal_flag. Размерность взаимодействий



финальная модель — обучение

ной split

протокол, что у ОКВЭД: train / validation
st по времени.

OOF / frozen score

На train — OOF boost score. На validation и test
— скор, не видевший эти таргеты.

Общий словарь регионов


Одна таблица 70 × 4 на регистрацию и
Регион не кодируется «как категория
бустинга».

$$-\text{mean}(y \cdot \ln(p_{\text{final}}) + (1-y) \cdot \ln(1-p_{\text{final}}))$$

≡, что у ОКВЭД. Early stopping по validation loss. Метрика — прирост Gini в п.п. к frozen boost score.

нальная модель — результаты и вывод

Train, n.n. Gini



Продукт	Train	ООТ
ПК		+1.2 п.п.
КК		+2.0 п.п.

по ПК
. Gini на ООТ и +1.2 на train. Сигнал переносится во времени, слабее -flat (+1.2 ООТ), устойчивее hierarchical (0 на ООТ).

Вывод по КК
На ООТ +0.3, на train +2.0. Эффект меньше и менее стабилен: выборка КК меньше. Train-прирост сам г не аргумент.

нельзя учить совместно
ричина, что у ОКВЭД: слишком большая разница в масштабе loss.

Чему не сработали более ранние эксперименты

ML-постановки проверяли четыре подхода «в лоб». Ни один не дал устойчивого прироста к готовому boost score.

Добавление признаков прямо в CatBoost

Коды и регионы высококардинальны и неравномерны. Для редкого значения признаков недостаточно, чтобы оценить отдельный эффект.

Нейросеть без boost score

Сеть видит только отрасль или регион и не видит персональный риск, который бустинг уже извлек из данных платежной дисциплины.

Смесь распределений

$\sum_k \pi_k \cdot P(y \mid \text{группа } k)$. Это безусловный PD группы. Большая часть уже в boost score. Прироста не было.

Factorization machines

$\hat{y} = w_0 + \sum_i w_i x_i + \sum_{i,j} \langle v_i, v_j \rangle x_i x_j$. Для редкого вектора v почти не оценивается. Прироста тоже не было.

ему остались две residual-ветки

тыре подхода конкурируют с бустингом

вечает: «насколько группа в среднем плохая». FM отвечает: «с какими признаками код пересекается». Residual-сеть отвечает иначе
лько этот ОКВЭД или эта пара регионов меняет шансы сверх уже учтенного сора».

постановка

и регион объясняют только Δ к log-odds готовой модели. Без этой постановки ранние эксперименты забирали сигнал, который бу
ет.

ОКВЭД flat

+0.7
ПК OOT, регион

0
ПК OOT, hierarchical